

SISTEMATIZACAO - MATEMATICA E ESTATISTICA PARA COMPUTACAO

Professor: Romes | Grupo: Sistematizacao-MMC

1 - Identificacao dos Componentes da Equipe

Nome Completo	Matricula	GitHub
Rafael R. Leite	72501342	@RafaelRLeite
Matheus Brito	72650414	@matheusbrito090108
Fernando Luca	72650534	@fernandoluca015
Italo da Silva Ferraz	72650588	@Italo-917

2 - Links do Projeto e Acessos

Item	Descricao e URL
Dados Crus (Dataset)	https://dados.gov.br/dados/conjuntos-dados/cadastro-nacional-da-pessoa-juridica---cnpj
Repositorio da Solucao	https://github.com/Sistematizacao-MMC/laboratorio-estatistico-interativo
Video de Demonstracao	https://drive.google.com/file/d/1x0gclwBwPL2EEWiOrFqr05dJ6aO1dxGR/view?usp=sharing

3 - Resumo Executivo da Solucao

A. Dataset Escolhido e Justificativa:

Foi selecionada a base de dados abertos do **Cadastro Nacional da Pessoa Juridica (CNPJ)** da Receita Federal do Brasil. Com mais de 49 milhoes de registros cadastrais, este conjunto fornece um ambiente realista para explorar distribuicoes financeiras complexas com alta assimetria e caudas pesadas (*heavy-tailed*), permitindo investigar o impacto de valores atipicos em tomadas de decisao estatistica.

B. Arquitetura e Modulos Implementados (Nucleo Autoral 'na unha'):

A aplicacao foi estruturada em Python desacoplando a interface grafica (**Streamlit**) do nucleo estatistico autoral (**src/core/pystatistics.py**). Todas as funcoes matematicas foram codificadas manualmente e validadas contra *NumPy* e *SciPy* via suite de 19 testes automatizados com *pytest*.

- **Modulo 0 (Carga e Pre-processamento):** Suporte a upload de CSV, leitura de arquivos locais e dataset de demonstracao integrado com 1.000 empresas simuladas.
- **Modulo 2 (Estatistica Descritiva Interativa):** Tendencia central, dispersao, separatrizes, boxplot interativo, tabela de frequencia e deteccao de outliers pelo metodo IQR (Tukey).
- **Modulo 3 (Probabilidade e Monte Carlo):** Simulacoes interativas da Lei dos Grandes Numeros (LGN) e do Teorema Central do Limite (TCL) com controle de parametros.
- **Modulo 4 (Distribuicoes Teoricas):** Ajuste e sobreposicao de curvas de densidade teoricas (Normal, Exponencial e Uniforme) sobre os histogramas reais.
- **Modulo 5 (Correlacao e Regressao Linear Simples):** Coeficiente de Pearson, reta por Minimos Quadrados Ordinarios (MQO), equacoes em LaTeX, R², predicao interativa e alerta de causalidade.
- **Modulo 6 (Relatorio de Descobertas):** Apresentacao analitica detalhada dos resultados diretamente na interface.

C. As 3 Principais Descobertas Estatisticas:

- **1. Assimetria Extrema em Variaveis Financeiras:** As variaveis de *Capital Social* e *Faturamento* apresentam media expressivamente superior a mediana (Media >> Mediana) e Coeficiente de Variacao (CV) superior a 150%. Os dados aderem com muito maior precisao a Distribuicao Exponencial/Pareto do que a Normal, demonstrando que menos de 2% das empresas concentram a maior parte do volume de capital (outliers severos). A mediana e o IQR comprovam ser medidas muito mais confiaveis que a media aritmetica.
- **2. Validacao Experimental do Teorema Central do Limite (TCL):** Mesmo partindo de populacoes com distribuicoes extremamente assimetricas ou multimodais, a distribuicao amostral das medias ($\bar{X}$) convergiu rigorosamente para uma Distribuicao Normal quando o tamanho amostral atingiu $n \geq 30$, com erro padrao convergindo para $\sigma/\sqrt{n}$. Isso legitima a aplicacao de intervalos de confianca e inferencia parametrica na base.
- **3. Relacao Linear por MQO e Alerta de Causalidade:** O modelo bivariado entre Capital Social e Faturamento indicou correlacao linear positiva moderada a forte ($r > 0.60$) e R² explicativo. Contudo, reforcou-se o postulado fundamental de que *correlacao nao implica causalidade*: variaveis ocultas de confusao (setor de atividade, maturidade de mercado e localizacao) exercem papel determinante sobre o desempenho economico.